

Universidad Nacional Guillermo Brown (UNaB)

Seminario

PLAN DE TRABAJO

Autor:

Villagra Turco, C. Ezequiel

Profesor:

Juan Domingo Gonzalez

23 de octubre de 2025

Índice

1. Objetivos	2
1.1. Objetivo General	2
1.2. Objetivos Específicos	2
2. Antecedentes	2
3. Metodología	3
4. Actividades	4
5. Factibilidad	4
5.1. Recursos Disponibles	4
5.2. Cronograma de Actividades	5
5.3. Factibilidad Temporal	5
6. Material adicional	5
6.1. Recursos Complementarios	5
6.2. Entregables Esperados	5
Referencias	6

1. Objetivos

Por medio de esta investigación se busca abordar el fenómeno de incendios forestales en la Patagonia Andina a partir de un enfoque basado en la recopilación de datos. A continuación, se establecen los objetivos que darán lugar al desarrollo del trabajo, orientados tanto a la comprensión de los factores asociados a la aparición de focos de calor como al diseño de herramientas que permitan su detección y predicción.

1.1. Objetivo General

Estudiar y comprender los incendios forestales de la Patagonia Andina por medio de datos derivados de instrumentos de teledetección y preprocesados con modelos robustos de consolidación.

1.2. Objetivos Específicos

- Recopilar y sistematizar la información necesaria y disponible para el desarrollo del proyecto, incluyendo datos satelitales, climatológicos y ambientales.
- Realizar la limpieza y procesamiento de los datos recopilados para su consolidación.
- Realizar un análisis exploratorio de los datos recopilados para identificar patrones y correlaciones entre las variables estudiadas y la ocurrencia de incendios.
- Implementar modelos de Machine Learning que permitan predecir la probabilidad de nuevos focos en una región específica.
- Evaluar la efectividad de los modelos desarrollados mediante la comparación de sus predicciones con datos históricos de incendios.

2. Antecedentes

Si bien el estudio de los incendios forestales se desarrolla desde hace décadas, su creciente frecuencia e intensidad, asociadas al calentamiento global, han demandado una comprensión más profunda de los factores de su dinámica. Para ello, el avance en tecnologías de teledetección y análisis de datos se ha erigido como una herramienta fundamental. La literatura científica respalda consistentemente el uso de datos satelitales para la detección y evaluación de incendios, mientras que la integración de información climática, topográfica y de vegetación ha sido clave para refinar los modelos predictivos actuales.

Un trabajo destacado en la región latinoamericana es el trabajo de Anzola et al. (2024), en el que desarrollaron un modelo de estimación para la prevención de incendios forestales en Colombia. Este estudio empleó una combinación de datos históricos, meteorológicos, topográficos y socioeconómicos como entrada para modelos predictivos de Machine Learning, específicamente Random Forest y Gaussian Naive Bayes, con el objetivo de evaluar su eficacia y proporcionar un marco valioso para investigaciones futuras.

En el ámbito de las arquitecturas de deep learning, Liang et al. (2019) demostraron la aplicabilidad de las redes neuronales recurrentes (RNN) para predecir la escala de los incendios. Utilizando una variante conocida como LSTM (Long Short-Term Memory) y alimentándola con registros históricos de incendios (similares a los proporcionados por sistemas como FIRMS de la NASA) junto con 11 variables meteorológicas, su modelo validó la factibilidad de esta aproximación.

Los artículos Jain et al. (2020) y Sengupta y Woodford (2025) presentan una revisión de modelos de Machine Learning con aplicación en el tema. El primero de ellos hace un análisis comparativo entre diferentes modelos de ML y brinda ejemplos de aplicación en distintos objetivos relacionados a la problemática mientras que el segundo brinda otro ejemplo de implementación y rendimiento en modelos de ML aplicados.

Finalmente, a nivel local, estudios como los de Medel (2014) y Martínez Saucedo e Inchausti (2023) ejemplifican el desarrollo de modelos predictivos dentro del territorio nacional argentino, en Córdoba y Pinamar, respectivamente. Si bien son trabajos de alcance acotado, comparten el espíritu central de esta investigación: aprovechar el poder del Machine Learning para predecir y gestionar el riesgo de incendios forestales.

3. Metodología

El desarrollo de la presente investigación se enmarcará en la metodología Cross Industry Standard Process for Data Mining (CRISP-DM) (Chapman et al., 1999). El proceso iniciará con la fase de comprensión del problema y los datos, en la cual se identificarán y recopilarán las variables meteorológicas críticas para la ocurrencia de incendios forestales en el área de estudio.

Posteriormente, se realizará la recolección y consolidación de datos provenientes de las API de Fire Information for Resource Management System (FIRMS) y ERA5-Land, con el fin de establecer un conjunto de datos unificado a nivel espacial y temporal. La etapa de preparación de datos incluirá procesos de limpieza, interpolación, integración y generación de variables derivadas. Luego, se llevará a cabo un análisis exploratorio de datos (Exploratory Data Analysis, EDA) para caracterizar patrones, correlaciones y comportamientos estacionales.

Finalmente, se abordará la fase de modelado mediante la aplicación y comparación de diferentes algoritmos de aprendizaje automático, con el objetivo de predecir la probabilidad de incendios en áreas específicas. El desempeño de los modelos será evaluado utilizando métricas de precisión y técnicas de validación cruzada.

4. Actividades

- **Entendimiento:** Análisis de literatura académica y técnicas desarrolladas en materia de incendios forestales, modelos predictivos y uso de datos satelitales (FIRMS, CONAE, Copernicus).
- **Preparación de datos:** Descarga de datos satelitales de fuentes como: FIRMS (NASA), Copernicus (UE). Tratamiento de datos para consolidación de un conjunto de datos robusto.
- **Análisis, modelado y evaluación:**
 1. Análisis exploratorio de datos (EDA) y visualización geoespacial.
 2. Implementación de modelos predictivos de Machine Learning (Random Forest, Support Vector Machine y Extreme Gradient Boosting).
 3. Evaluación de modelos mediante métricas como precisión, recall, F1-score y AUC-ROC.
- **Elaboración de informe:** Recopilación de resultados y redacción del documento final.

5. Factibilidad

La factibilidad del este trabajo se sustenta en la disponibilidad de datos abiertos, herramientas tecnológicas de libre acceso y amplia bibliografía especializada en el área de estudio.

Es considerada la capacidad computacional necesaria (ya sea entorno local o uso de recursos en la nube) para llevar a cabo los análisis planteados.

El cronograma de trabajo será acotado pero realista, su diseño estará pensado para ser ejecutado en un plazo máximo de dos meses.

5.1. Recursos Disponibles

- **Datos:** Acceso a datos satelitales provenientes de programas internacionales como Copernicus (UE) y FIRMS (NASA), disponibles mediante APIs y a nivel nacional gracias a la CONAE.
- **Software:** Entorno de desarrollo y programación en Python, complementando con librerías de uso extendido en ciencia de datos (pandas, scikit-learn, geopandas, entre otras).
- **Bibliografía:** Acceso a literatura académica, artículos y reportes técnicos disponibles en internet.
- **Infraestructura:** Hardware necesario para el procesamiento de imágenes y ejecución de modelos de aprendizaje automático. En su defecto o a fines de optimizar tiempos, se montará una infraestructura virtual en un Droplet de DigitalOcean.

5.2. Cronograma de Actividades

Actividad	Inicio	Fin	Entregable
Revisión bibliográfica	23/08	06/09	Plan de Trabajo
Recolección y preparación de datos	06/09	05/10	Dataset completo y procesado
Análisis preliminar	06/10	10/10	Resultados iniciales
Modelado y evaluación	11/10	31/10	Hallazgos principales
Redacción final	01/11	24/11	Informe completo

Cuadro 1: Cronograma de trabajo

5.3. Factibilidad Temporal

El plan de trabajo ha sido diseñado para su desarrollo en un plazo máximo de dos meses (contemplando un margen de flexibilidad ante imprevistos), con actividades secuenciales que permiten avanzar de manera progresiva desde la revisión bibliográfica hasta la redacción del informe final.

6. Material adicional

6.1. Recursos Complementarios

- **Repositorio de datos:**
 - FIRMS (NASA): <https://firms.modaps.eosdis.nasa.gov/>
 - Copernicus Climate Data Store (CDS): <https://cds.climate.copernicus.eu/>
 - CONAE (Comisión Nacional de Actividades Espaciales): <https://catalogos.conae.gov.ar/catalogo/catalogo.html>
 - Open-Meteo: <https://open-meteo.com/en/docs>
- **Código fuente:** <https://github.com/HunterCitto/199---Seminario-Final>
- **Visualizaciones:** Dashboards interactivos desarrollados en Jupyter Notebooks.
- **Documentación:** Manuales técnicos, protocolos de investigación y guías metodológicas utilizadas.

6.2. Entregables Esperados

1. Plan de Trabajo.
2. Presentaciones de avance.
3. Repositorio con datos y código reproducible.
4. Documentación final.

Referencias

- Anzola, J. D., Fuentes, L. D., & Rodríguez, E. M. (2024). *Desarrollo de un modelo de estimación para la prevención de incendios forestales en Colombia* [Tesis de maestría]. Universidad del Norte. <http://hdl.handle.net/10584/11968>
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (1999). *The CRISP-DM 1.0 Step-by-Step Data Mining Guide* (inf. téc.). SPSS Inc. Chicago. <https://www.ibm.com/docs/es/spss-modeler/saas?topic=dm-crisp-help-overview>
- Copernicus Climate Change Service (C3S). (2023). *ERA5-Land: Hourly Data on Single Levels from 1950 to Present*. Copernicus Climate Data Store (CDS). <https://doi.org/10.24381/cds.e2161bac>
- Jain, P., Coogan, S. C. P., Subramanian, S. G., Crowley, M., Taylor, S., & Flannigan, M. D. (2020). A Review of Machine Learning Applications in Wildfire Science and Management. *Environmental Reviews*, 28(4), 478-505. <https://doi.org/10.1139/er-2020-0019>
- Liang, H., Zhang, M., & Wang, H. (2019). A Neural Network Model for Wildfire Scale Prediction Using Meteorological Factors. *IEEE Access*, 7. <https://doi.org/10.1109/ACCESS.2019.2957834>
- Martínez Saucedo, A., & Inchausti, P. E. (2023). Predicción de incendios forestales mediante modelos de machine learning [Evento celebrado del 3 al 6 de octubre de 2022], 3 al 6 de octubre de 2022. https://sedici.unlp.edu.ar/bitstream/handle/10915/149568/Documento_completo.pdf?sequence=1&isAllowed=y
- Medel, R. (2014). Predicción de incendios forestales en la provincia de Córdoba mediante Modelos de Aprendizaje Supervisados [Taller de Investigadores en Ciencias de la Computación]. https://sedici.unlp.edu.ar/bitstream/handle/10915/41936/Documento_completo.pdf?sequence=1
- NASA FIRMS. (2024). *Fire Information for Resource Management System (FIRMS)*. NASA Earth Science Data y Information System (ESDIS). <https://firms.modaps.eosdis.nasa.gov>
- Sengupta, A., & Woodford, B. J. (2025). Recent advances in explainable Machine Learning models for wildfire prediction. *Applied Computing and Geosciences*, 27, 100266. <https://doi.org/https://doi.org/10.1016/j.acags.2025.100266>