



Incendios forestales de la Patagonia Andina: Una aproximación con modelos de aprendizaje automático.

Villagra Turco C. Ezequiel, González Juan D.

Licenciatura en Ciencias de Datos

Resumen:

Esta tesis implementa un proceso automatizado, flexible y escalable para la recolección y procesamiento de datos, con el objetivo de consolidar un conjunto de datos integral para el estudio de incendios forestales. El propósito central del estudio es implementar y evaluar modelos predictivos de aprendizaje automático que estimen la probabilidad de ocurrencia de incendios forestales basándose en condiciones meteorológicas y variables ambientales de una región específica. [SIGUE...].

Palabras clave: Predicción de incendios forestales, aprendizaje automático, CRISP-DM, datos meteorológicos, prevención de incendios.

Noviembre 2025

A mi vieja...
ejemplo de inteligencia,
valentía y fortaleza,
humanidad y amor infinito.

Índice

Introducción	3
Antecedentes	4
Datos	5
Datos meteorológicos	5
Datos de focos de calor	6
Adquisición y tratamiento	7
Tratamiento de datos meteorológicos.....	7
Fire Weather Index	8
Tratamiento de datos de focos de calor	9
Unificación de datos.....	9
Análisis exploratorio	11
Aplicación de modelo/s.....	14
Resultados	14
Conclusiones	14
Apéndices.....	14
I - Desarrollo de interfaces con APIs.....	14
II - Implementación de Variables Calculadas para FWI.....	15
Documentos de referencia.....	16
Documentos aplicables.....	16

Introducción

Los bosques andino-patagónicos constituyen una de las reservas de biodiversidad mejor conservadas de Argentina y representan un ecosistema templado de relevancia a nivel global. No obstante, su integridad se encuentra amenazada por el incremento en frecuencia e intensidad de los incendios forestales, que durante las temporadas estivales 2020-2025 alcanzaron magnitudes sin precedentes en las últimas tres décadas. Esta tendencia, documentada en informes recientes [1][2][3], no constituye un evento aislado, sino un patrón recurrente que afecta también a otras ecorregiones críticas del país.

La problemática central radica en el aumento de incendios en áreas protegidas, cuya propagación y duración se ven potenciadas por factores ambientales y climatológicos específicos. Si bien existen análisis descriptivos sobre el impacto de estos desastres, persiste una brecha en la aplicación de herramientas cuantitativas para la prevención activa. Cabe destacar que la prevención y combate de incendios ha sido declarada de interés público provincial mediante la Ley N.º 5243 de Río Negro, que subraya la necesidad de proteger el patrimonio ambiental. Dicha ley establece: "*Declárase de interés público provincial la prevención, presupresión y combate de los incendios forestales y rurales, como medio tendiente a la protección de la vida y la seguridad de las personas y a la preservación del patrimonio ambiental y económico de la provincia.*" (Legislatura de la Prov. de Río Negro, 2017, art. 1).

Frente a este desafío, los avances en ciencia de datos y la creciente disponibilidad de información geoespacial, series temporales climatológicas y registros históricos, entre muchas otras fuentes, ofrecen una oportunidad única para transitar de un enfoque reactivo a uno proactivo.

En este trabajo de investigación se aplicará la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining) [10] para establecer un marco de trabajo flexible y escalable. El principal resultado consistirá en un conjunto de datos consolidado para el estudio de incendios, inspirado en el Canadian Fire Spread Dataset (CFSD) [11]. Sobre este recurso, se implementarán y evaluarán modelos predictivos como prueba de concepto, demostrando así el valor del dataset como pilar para el desarrollo de sistemas de alerta temprana.

Antecedentes

El estudio de los incendios forestales es un campo de investigación consolidado con varias décadas de trayectoria. En los últimos años, con los conceptos de calentamiento global y cambio climático que han cobrado gran relevancia, y con ello, la necesidad de entender mejor los factores que contribuyen a la ocurrencia y propagación de incendios forestales. El avance tecnológico, especialmente en el ámbito de la teledetección y el análisis de datos, ha abierto nuevas posibilidades para el estudio de estos eventos. Diversos estudios han demostrado la eficacia de utilizar datos satelitales para detectar áreas afectadas por incendios y evaluar su extensión. Además, la integración de datos climáticos, topográficos y de vegetación ha permitido desarrollar modelos predictivos más precisos.

Un trabajo destacado en la región latinoamericana es el trabajo de Anzola et al. (2024) [4], en el que desarrollaron un modelo de estimación para la prevención de incendios forestales en Colombia. Este estudio empleó una combinación de datos históricos, meteorológicos, topográficos y socioeconómicos como entrada para modelos predictivos de Machine Learning, específicamente Random Forest y Gaussian Naive Bayes, con el objetivo de evaluar su eficacia y proporcionar un marco valioso para investigaciones futuras.

En el ámbito de las técnicas de modelado, Liang et al. (2019) [5] utilizó una red neuronal recurrente (RNN) de tipo LSTM (Long Short-Term Memory) para predecir la escala de incendios. Es de particular interés que su modelo se nutrió de registros históricos de focos de incendio y 11 variables meteorológicas, fuentes de información análogas a las que proveen servicios como NASA FIRMS (Fire Information for Resource Management System) [15] y CONAE (Comisión Nacional de Actividades Espaciales) [14], que son pilares en la presente investigación. El éxito de su enfoque demostró la factibilidad de predecir la escala de los incendios utilizando estas tecnologías.

Los artículos Jain et al. (2020) [6] y Sengupta y Woodford (2025) [7] presentan una revisión de modelos de Machine Learning con aplicación en el tema. El primero de ellos hace un análisis comparativo entre diferentes modelos de ML y brinda ejemplos de aplicación en distintos objetivos relacionados a la problemática mientras que el segundo brinda otro ejemplo de implementación y rendimiento en modelos de ML aplicados.

Finalmente, a nivel local, estudios como los de Medel (2014) [8] y Martínez Saucedo e Inchausti (2023) [9] ejemplifican el desarrollo de modelos predictivos dentro del territorio nacional argentino, en Córdoba y Pinamar, respectivamente. Si bien son trabajos de alcance acotado, comparten el espíritu central de esta investigación: aprovechar el poder del Machine Learning para predecir y gestionar el riesgo de incendios forestales.

Datos

El dataset desarrollado en este trabajo se construyó a partir de dos fuentes de datos principales. Ambas proveen información obtenida mediante teledetección satelital, complementada con técnicas de modelado y asimilación que mejoran la precisión de las observaciones.

Datos meteorológicos

Para los datos meteorológicos se ha seleccionado como fuente de información el producto de reanálisis provisto por el servicio de almacén de datos climáticos (Climate Data Store, CDS) del proyecto Copernicus de la Unión Europea (UE): ERA5-Land **¡Error! No se encuentra el origen de la referencia..**

ERA5-Land es un conjunto de datos de reanálisis global, producido por el Centro Europeo de Pronósticos Meteorológicos a Medio Plazo (ECMWF), que proporciona una descripción consistente y detallada de las variables de la superficie terrestre desde 1950 hasta casi en tiempo real. Se genera mediante la ejecución retroactiva del modelo numérico de la tierra del ECMWF (HTESSEL, por sus siglas en inglés) utilizando como entrada las observaciones meteorológicas asimiladas del reanálisis de ERA5, pero con una resolución espacial mejorada.

<i>Característica</i>	<i>Descripción</i>
<i>Producto</i>	ERA5-Land
<i>Administrador</i>	Centro Europeo de Pronósticos Meteorológicos a Medio Plazo (ECMWF)
<i>Programa</i>	Servicio de Cambio Climático de Copernicus (C3S)
<i>Naturaleza del Dato</i>	Reanálisis (Reconstrucción numérica mediante modelado y asimilación de datos)
<i>Cobertura Espacial</i>	Global
<i>Resolución Espacial</i>	9 km (0.1° x 0.1° en latitud/longitud)
<i>Resolución Temporal</i>	Horaria
<i>Periodo de Registro</i>	Desde 1950 hasta casi tiempo real (con un desfase de ~2-3 meses)
<i>Metodología</i>	Re-ejecución del modelo de superficie terrestre HTESSEL del ECMWF, forzado por las condiciones meteorológicas del reanálisis ERA5.
<i>Principales Variables de Superficie Terrestre</i>	Temperatura del suelo (a múltiples profundidades)
	Humedad del suelo (en los 4 niveles superiores)
	Contenido de agua en la nieve
	Cubierta de nieve
	Evapotranspiración
<i>Principales Variables Atmosféricas en Superficie</i>	Temperatura del aire a 2 m
	Punto de rocío a 2 m
	Precipitación total
	Radiación solar superficial
	Velocidad del viento a 10 m
	Presión a nivel de la superficie

<i>Principales Variables del Balance Hídrico</i>	Escorrentía superficial
	Escorrentía subsuperficial
	Estudios hidrológicos y de recursos hídricos
	Investigación agrícola y de vegetación
	Análisis del clima regional y estudios de cambio climático
	Validación de otros modelos de superficie

Tabla 1 - ERA5-Land especificaciones.

La principal ventaja de ERA5-Land sobre otros conjuntos de datos de reanálisis es su alta resolución espacial y temporal combinada con una extensa línea de tiempo. Esto lo hace particularmente adecuado para estudios que requieren un análisis detallado de procesos de superficie como:

- Monitoreo de sequías y humedad del suelo.
- Estudios de agricultura e hidrología.
- Análisis del clima a escala regional y local.
- Investigación del balance energético y hídrico terrestre.

En esencia, ERA5-Land sirve como un "simulador del pasado" del sistema terrestre, llenando los vacíos donde no existen observaciones directas y proporcionando un conjunto de variables físicamente consistentes entre sí.

Datos de focos de calor

La obtención de datos de focos de calor se pensó, en una primera instancia, hacer uso de los productos distribuidos por parte de la CONAE [14]. Sin embargo, la falta de una API para el acceso programático a los datos motivó que se terminara optando por el producto de la NASA, distribuido a través del sistema FIRMS [15]. Se obtuvieron datos de ambas fuentes y, en una comparación de registros, se observó el uso de los mismos instrumentos de muestreo:

<i>Característica</i>	<i>Satélites MODIS</i>		<i>Satélites VIIRS</i>	
	TERRA (EOS AM-1)	AQUA (EOS PM-1)	Suomi NPP	NOAA-20 (JPSS-1)
<i>Administrador</i>	NASA	NASA	NASA / NOAA	NASA / NOAA
<i>Lanzamiento</i>	18 de diciembre de 1999	4 de mayo de 2002	28 de octubre de 2011	18 de noviembre de 2017
<i>Tipo de Órbita</i>	Heliosíncrona	Heliosíncrona	Heliosíncrona	Heliosíncrona
<i>Altura de la Órbita</i>	705 km	705 km	824 km	824 km
<i>Hora Local de Cruce por el Ecuador</i>	10:30 AM (Descendente)	1:30 PM (Ascendente)	1:30 PM (Ascendente)	1:30 PM (Ascendente)
<i>Resolución Espacial (Bandas)</i>	1000 m	1000 m	375 m (I-bands), 750 m (M-bands)	375 m (I-bands), 750 m (M-bands)
<i>Ancho de Franja</i>	2330 km	2330 km	3000 km	3000 km

<i>Periodo de Revisita</i>	~1-2 días	~1-2 días	~ 1 día (global)	~ 1 día (global)
<i>Aplicaciones Principales</i>	Monitoreo de vegetación, océanos, temperatura superficial, incendios, nubes, aerosoles.	Monitoreo de vegetación, océanos, temperatura superficial, incendios, nubes, aerosoles.	Monitoreo ambiental y climático, meteorología, océano, tierra, criosfera, incendios.	Monitoreo ambiental y climático, meteorología, pronóstico del tiempo, océano, tierra, incendios.

Tabla 2 - Plataformas satelitales para datos.

La diferencia en la hora de paso es relevante, ya que TERRA (paso a.m.) es ideal para observar condiciones despejadas, mientras que AQUA, Suomi NPP y NOAA-20 (paso p.m.) capturan la máxima actividad térmica del día, lo que los hace especialmente útiles para la detección de incendios y el estudio de la dinámica atmosférica de la tarde.

Adquisición y tratamiento

La adquisición de los datos se realiza mediante el uso de las Interfaces de Programación de Aplicaciones (API) provistas por los administradores de la información. Estas interfaces funcionan como piezas de código que permiten a dos aplicaciones comunicarse entre sí para compartir información y funcionalidades.

Esta estrategia de adquisición de datos permite que la solución final sea flexible y escalable. A modo de ejemplo, la consulta base para la adquisición consiste en coordenadas geográficas y una ventana de tiempo que se parametrizan como variables del proyecto. Esto permite que sean fácilmente modificables según el objeto de estudio; se puede pasar rápidamente de obtener información para un área de 200 km² a abarcar todo el territorio argentino.

La consulta programática a las API representa la capa de ingesta de datos del proyecto, los cuales son posteriormente tratados para su armonización e integración en el conjunto de datos consolidado.

¿Apéndice I? Breve espacio técnico con lógica de construcción de interfaz hacia la API y almacenamiento de datos.

Tratamiento de datos meteorológicos

Los datos meteorológicos recibidos de los productos ERA5-Land [12] son un producto de reanálisis, por lo que no requieren limpieza o revisión por valores faltantes. El tratamiento en esta etapa consiste, por lo tanto, incorporación de variables calculadas: se utilizan los valores base para calcular el conjunto de variables derivadas que componen el Fire Weather Index (FWI) [16].

Fire Weather Index

El sistema canadiense de índice meteorológico de incendios forestales (FWI) consta de seis componentes que explican los efectos de la humedad del combustible y las condiciones climáticas sobre el comportamiento del fuego.




Diagrama 1 - Fire Weather Index

Los primeros tres componentes (FFMC, DMC, DC) son clasificaciones numéricas del contenido de humedad del suelo y otra materia orgánica muerta. Sus valores aumentan a medida que disminuye el contenido de humedad:

- **Fire Fuel Moisture Code (FFMC)**, humedad de la hojarasca y otros combustibles finos curados. Es un indicador de la facilidad de ignición y la inflamabilidad del combustible fino.
- **Duff Moisture Code (DMC)**, contenido promedio de humedad en las capas orgánicas poco compactadas de profundidad moderada. Es un indicador del consumo de combustible en capas moderadas de hojarasca y material leñoso de tamaño mediano.
- **Drought Code (DC)**, contenido promedio de humedad de capas orgánicas profundas y compactas. Es un indicador útil de los efectos de la sequía estacional en los combustibles forestales y la combustión latente en capas profundas.

Los tres componentes restantes (ISI, BUI, FWI) son índices de comportamiento del fuego, que representan la tasa de propagación, el combustible disponible y la intensidad frontal. Estos valores aumentan a medida que aumenta el peligro de incendio:

- **Initial Spread Index (ISI)**, velocidad de propagación prevista del incendio. Se basa en la velocidad del viento y el FFMCI. Al igual que el resto del sistema FWI, no considera el tipo de combustible.
- **Buildup Index (BUI)**, cantidad total de combustible disponible para la combustión. Se basa en el DMC y el DC.
- **Fire Weather Index (FWI)**, intensidad de los incendios. Se basa en el ISI y el BUI, y se utiliza como índice general de peligro de incendio.

La estrategia inicial contemplaba trabajar con registros meteorológicos de frecuencia de 6 horas. Sin embargo, se observó que afectaba la validez del cálculo del FWI, dado que el diseño original del índice hace uso del acumulado de precipitaciones en un período de 24 horas. Para alinear el procesamiento con los requisitos del índice, se decidió cambiar la frecuencia los datos, un ajuste que fue fundamental para obtener valores del FWI coherentes.

¿Apéndice II? Espacio técnico con el detalle de cálculos/formulas y su implementación para obtener los campos calculados.

Tratamiento de datos de focos de calor

El conjunto de datos de focos de calor se filtró y reestructuro por completo. En primer lugar, se filtraron los registros para excluir aquellos etiquetados con confianza baja (confidence: 'l'). Esta decisión es una práctica estándar que se fundamenta en la alta probabilidad de falsos positivos en esta categoría. Tal como lo documenta la NASA [17], estos registros frecuentemente corresponden a errores de detección, como reflejos solares en superficies lisas, y no a incendios reales.

Posteriormente, los datos filtrados fueron reestructurados para alinear su resolución espacial con la de los datos meteorológicos (la grilla de ~10km de ERA5-Land). Este proceso de *gridding* consistió en asignar cada foco de calor a la celda específica de la grilla de ERA5-Land dentro de la cual se encontraba mediante el redondeo los valores de latitud y longitud a un solo decimal. Una vez asignados, se agrupó la información por celda de grilla (coordenadas) y por fecha para alinear la resolución temporal a 24 horas. Finalmente, para cada grupo (coordenadas-día) se realizó la agregación de dos variables: el conteo total de focos de incendio y el promedio de la energía radiactiva del fuego (FRP).

Unificación de datos

Una vez preparados ambos conjuntos de datos (el meteorológico y el de focos de calor), se procedió a su unificación.

Esta fusión se realizó utilizando una clave de unión compuesta por las tres variables que definen unívocamente cada observación en la grilla espaciotemporal: fecha, latitud y longitud.

El resultado es un único conjunto de datos consolidado. En este conjunto final, cada fila representa una celda de la grilla (~10km) en un día específico, y contiene tanto las variables meteorológicas con los 6 componentes del FWI como las variables objetivo con el conteo de focos y FRP promedio.

Si bien la resolución temporal fue escalada a una frecuencia diaria, tras la consolidación del dataset se observó un problema de discontinuidad temporal en las variables de focos de calor (*num_focos* y *frp_mean*). Para ejemplificar, en una celda determinada se podía registrar el inicio de un incendio el 26 de diciembre y su crecimiento los días siguientes, pero luego reportar '0' focos el 31 de diciembre y el 1 de enero, para volver a mostrar una presencia contundente días después.

Esta "desaparición" del fuego es un artefacto de la detección satelital (probablemente debido a nubosidad, humo o la hora de paso del satélite) y no la realidad física del evento.

Para corregir estos registros anómalos y obtener una serie temporal más realista de la actividad del fuego, se implementó un proceso de interpolación y suavizado. Este tratamiento se aplicó de forma independiente a cada celda de la grilla (latitude, longitude) y consistió en los siguientes pasos:

1. Identificación del Período de Incendio: Para cada celda, se identificó la fecha del primer foco detectado (*fecha_inicio*) y la fecha del último (*fecha_fin*).
2. Interpolación Lineal: Se aplicó una interpolación lineal a las variables *num_focos* y *frp_mean*, pero únicamente dentro del período de incendio (entre *fecha_inicio* y *fecha_fin*). Este paso rellenó los valles de 'cero' anómalos.
3. Suavizado Temporal: Inmediatamente después de interpolar, se aplicó un suavizado mediante una media móvil con una ventana de 3 días, para reducir el ruido de alta frecuencia en las mediciones.

Finalmente, todos los valores de *num_focos* y *frp_mean* fuera del período de incendio (antes de *fecha_inicio* y después de *fecha_fin*) se rellenaron explícitamente con cero.

Con esto concluye la etapa de construcción del conjunto de datos que servirá como entrada a los modelos de Machine Learning. Se ha consolidado un dataset con información consistente que abarca el período de diciembre de 2024 a marzo de 2025. El alcance geográfico del estudio se centra en la región andino-patagónica de la provincia de Río Negro, extendiéndose desde su límite norte con Neuquén hasta su límite sur con la provincia de Chubut.

Como resumen final de su estructura, el dataset consolidado es un panel de datos espaciotemporales: cada fila representa una celda única de la grilla en un día específico. Para cada registro, el conjunto de datos provee:

1. Predictores Meteorológicos: Información meteorológica más el conjunto de las 6 variables del FWI.
2. Variables Objetivo: El conteo de focos, el promedio de FRP y la etiqueta binaria, ya filtradas, interpoladas y suavizadas

Análisis exploratorio

Resolución

El análisis exploratorio se utilizó en primera instancia para validar la coherencia del conjunto de datos resultante, es decir, que el procesamiento de los datos crudos obtenidos desde las APIs tenga coherencia y consistencia a fin de aplicar aprendizaje automático.

En primer lugar, se verificó la información relacionada a la geolocalización con un resumen de la grilla y la distribución de frecuencias por coordenadas, dado que, para cada par de longitud y latitud, debería haber la misma cantidad de registros según la serie temporal del conjunto:

<i>Característica</i>	<i>Valor</i>
<i>Dimensiones (Celdas)</i>	11 × 11
<i>Total, celdas</i>	121
<i>Resolución Angular</i>	0.10° × 0.10°
<i>Resolución Métrica Aproximada (m)</i>	11107 × 8285
<i>Área Total Aproximada (kms)</i>	111.1 × 82.9
<i>Área Total Aproximada (kms²)</i>	9201,7
<i>Extensión Longitudinal</i>	-72.00° a -71.00°
<i>Extensión Latitudinal</i>	-42.00° a -41.00°

Tabla 3 - Resumen métrico de la grilla obtenida (sección 4.1 de notebook).




Imagen 1 - Validación con origen de datos FIRMS.




Imagen 2 - Mapeo de coordenadas y frecuencia de observaciones.

Fire Weather Index

Una vez constatada la coherencia geográfica con el área y el rango de fechas de estudio, se procedió a generar código para analizar los datos meteorológicos y relacionados a FWI:




Imagen 3 - Análisis temporal de FWI en -41.5, -71.8.

Los gráficos mostrados son generados a partir de un solo par de coordenadas, de otra forma quedaría inconsistente. En el análisis temporal se puede evidenciar la coherencia de las variables derivadas del FWI en relación con las meteorológicas, por ejemplo, como el efecto de las precipitaciones llevan el índice a prácticamente cero y la influencia de la velocidad del viento. También se observa la gran precipitación del día 23 de febrero de 2025 que fue la principal causa de la desaparición de los focos de calor.




Imagen 4 - Matriz de correlación de variables meteorológicas y FWI.




Imagen 5 - Distribución de categorías de riesgo según FWI.

<i>Métrica</i>	<i>Valor</i>
Período de Análisis	2024-12-01 a 2025-03-28
Puntos Geográficos	121
Días con Incendios	21 (1.6% del período)
Rango	0.00 - 54.51
Promedio	9.07
Máximo Registrado	54.51
FWI Promedio (Días con Incendio)	6.05
FWI Promedio (Días sin Incendio)	9.12

Tabla 4 - Resumen FWI para el periodo de estudio.

Focos de calor

Aplicación de modelo/s

Resultados

Conclusiones

Apéndices

I - Desarrollo de interfaces con APIs

Las interfaces de comunicación hacia APIs desarrolladas fueron la de obtención de datos FIRMS y ERA-5, con respaldo de la documentación [18] y [19].




Diagrama 2 - Clase FIRMSTools desarrollada.

II - Implementación de Variables Calculadas para FWI

Documentos de referencia

- [1] Greenpeace. (2024, abril). [*Incendios Forestales en los Bosques Andino Patagónicos de Argentina.*](#)
- [2] Greenpeace. (2025, mayo). [*Incendios Forestales en los Bosques Andino Patagónicos de Argentina.*](#)
- [3] Servicio Nacional de Manejo del Fuego. (s.f.). [*Reporte mensual de alerta temprana.*](#) Gobierno de Argentina.
- [4] Anzola, J. D., Fuentes, L. D., y Rodríguez, E. M. (2024). [*Desarrollo de un modelo de estimación para la prevención de incendios forestales en Colombia*](#) [Tesis de pregrado, Universidad del Norte]. Repositorio Institucional Manglar.
- [5] Liang, H., Zhang, M., & Wang, H. (2019). [*A Neural Network Model for Wildfire Scale Prediction Using Meteorological Factors.*](#) *IEEE Access*, 7, 176746-176755.
- [6] Piyush Jain, Sean C.P. Coogan, Sriram Ganapathi Subramanian, Mark Crowley, Steve Taylor, and Mike D. Flannigan. 2020. [*A review of machine learning applications in wildfire science and management.*](#) *Environmental Reviews*.
- [7] Sengupta, A., & Woodford, B. J. (2025). [*Recent advances in explainable Machine Learning models for wildfire prediction.*](#) *Applied Computing and Geosciences*, 27, 100266.
- [8] Cardenas, M., Medel, R., Castillo, J., Vázquez, J. C., & Casco, O. (2015). [*Modelos de Aprendizaje Supervisados: aplicaciones para la predicción de incendios forestales en la provincia de Córdoba.*](#) En *XVII Workshop de Investigadores en Ciencias de la Computación (WICC 2015)*. Universidad Nacional de La Plata.
- [9] Martinez Saucedo, A., & Inchausti, P. E. (2020). [*Predicción de incendios forestales mediante modelos de Machine Learning.*](#) En *XXVI Congreso Argentino de Ciencias de la Computación (CACIC)*.

Documentos aplicables

- [10] CRISP-DM (1996). [*CRoss-Industry Standard Process for Data Mining \(CRISP-DM\).*](#)
- [11] Barber, Q. E., Jain, P., Whitman, E., Thompson, D. K., Guindon, L., Parks, S. A., Wang, X., Hethcoat, M. G., & Parisien, M. A. (2024). [*The Canadian Fire Spread Dataset.*](#) *Scientific data*, 11(1), 764.
- [12] Muñoz Sabater, J. (2019): [*ERA5-Land hourly data from 1950 to present.*](#) Copernicus Climate Change Service (C3S) Climate Data Store (CDS).
- [13] European Centre for Medium-Range Weather Forecasts. (2024). [*3.3 OpenIFS: Surface Model HTESSSEL.*](#) OpenIFS Documentation.

- [14] Comisión Nacional de Actividades Espaciales. (s. f.). [*Catálogo de focos de calor*](#). CONAE.
- [15] NASA. [*Fire Information for Resource Management System \(FIRMS\)*](#). NASA Earth Observing System Data and Information System (EOSDIS).
- [16] Wagner, C. E. van, ISBN: 0-662-15198-4, Canadian Forestry Service, [*Development and structure of the Canadian Forest Fire Weather Index System*](#), (1987).
- [17] wxedward (2024, 13 febrero). [*FIRMS: What is the detection confidence?*](#) Earthdata Forum.
- [18] NASA FIRMS. *FIRMS Web Services*. [*NASA Earth Science Data and Information System \(ESDIS\)*](#).
- [19] Copernicus Climate Change Service (C3S). [*How to API*](#). Copernicus Knowledge Base.